

课堂反馈 1

判断题

共 14 题

1. (易) 在进行回归分析时, 如果模型显示自变量 X (如: 是否临近地铁) 对因变量 Y (单位面积房价) 的影响在统计学上显著, 则可以判定 X 是导致 Y 变化的因果原因。 ()
2. (中) 在进行线性回归模型选择时, 由于 BIC 准则相比 AIC 准则对模型复杂度的惩罚力度更大 (特别是当样本量较大时), 因此在同一数据集上, 使用 BIC 准则选出的最终模型包含的自变量个数往往多于使用 AIC 准则选出的变量个数。 ()
3. (中) 在线性回归模型诊断中, 若残差图呈现“喇叭状”, 说明模型存在异方差现象, 对因变量做对数变换是唯一的解决方法。 ()
4. (易) 在线性回归模型的假设检验中, F 检验是用来检验每一个变量对因变量 Y 的影响是否显著的。 ()
5. (易) 在多元线性回归模型中, 调整后的 R^2 一定小于普通 R^2 , 且可用于不同自变量个数模型的比较。 ()
6. (中)

【题目】

在二手房数据集中, 我们发现不同地区的房价差异巨大, 比如: 西城某学区房, 单价约13.5万/平米; 石景山某非学区房, 单价约3.6万/平米。针对上述数据中存在的极值拉高平均水平现象, 我们将模型改进为对数线性模型: $\log(y) = \beta_0 + \beta_1 x_1 + \cdots + \epsilon$ 。假设我们在对数线性模型中, 计算出 school (是否为学区房, 1代表是, 0代表否) 这一自变量的系数估计值为 0.171。那么我们可以解读为: “在控制其他因素不变时, 学区房单位面积房价比非学区房平均高出 0.171 万元/平方米”。

7. (难) 在北京市二手房房价的对数线性回归模型中, 加入“城区 $\times$ 学区”的交互项后, 学区变量的主效应系数为负值, 说明学区房的单位面积房价整体低于非学区房, 该交互项的引入无实际意义。 ()
8. (中)

题干: 对于包含截距项的多元线性回归模型

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \mu_i$$

采用 OLS 估计。若模型遗漏了对 Y 具有显著正向影响的变量 Z , 且 Z 与 X_1, X_2 的总体相关系数均为 0, 则原有模型的 $\hat{\beta}_1, \hat{\beta}_2$ 一定存在向上的遗漏变量偏误。

9. (易) 在线性回归模型中, 随着自变量个数的增加, 判决系数 R^2 总是会趋于增加 (或至少保持不变), 因此在比较包含不同数量自变量的模型时, R^2 是衡量模型优劣的最科学指标。 ()
10. 在分析某城市共享单车骑行时长分布时, 如果直方图显示数据右偏, 则可以判断大多数用户骑行时间较长。 ()

11. (易)

$AIC = n(\log \frac{RSS}{n}) + 2p$, 其中 $n(\log \frac{RSS}{n})$ 项表示模型的复杂程度, $2p$ 项表示模型的拟合优度。

12. (中) 在线性模型中, QQ 图常用于检验自变量对因变量是否具有显著影响。()

13. (易) 在多元线性回归模型中, 若某个自变量的方差膨胀因子 (VIF) 为 8, 则该变量与其他自变量之间存在严重的多重共线性, 必须从模型中剔除。()

14. (易) 在 QQ 图中, 若 QQ 图散点偏移 $y=x$ 参考线较大, 我们可以认为误差项存在异方差, 即假设 $\text{Var}(\varepsilon)=\sigma^2$ 不成立。()

选择题

共 14 题

1. (中) 下列关于线性回归模型诊断与优化的说法中, 错误的一项是 ()

- A. 残差图呈现明显的喇叭状, 是模型存在异方差问题的典型特征
- B. 对因变量做对数变换, 可改善模型的异方差问题与残差非正态问题
- C. 自变量的方差膨胀因子为 6.2, 说明该变量存在严重的多重共线性, 须从模型中剔除
- D. Cook 距离用于识别样本中的强影响点, 判断单个样本对模型拟合结果的影响程度

2. (中) 在评估线性回归模型的残差图 (Residuals vs Fitted) 时, 如果观察到残差图呈现“喇叭状”, 即残差的波动随着预测值的增加变得剧烈, 这说明模型违反了哪项基本假设? PPT 中推荐的解决方案是什么?

- A. 存在多重共线性; 解决方案是计算方差膨胀因子并剔除变量
- B. 遗漏了重要的自变量; 解决方案是加入新的自变量, 或者考虑非线性模型
- C. 误差不服从正态分布; 解决方案是观察 QQ 图并剔除 Cook 距离过大的异常点
- D. 存在异方差现象; 解决方案是对因变量做对数变换 (如果因变量取值为正), 再进行建模

3. (中) 关于线性回归模型中的 F 检验和 t 检验, 下列说法正确的是 ()

- A. F 检验用于检验单个自变量的显著性, t 检验用于检验所有自变量的整体显著性
- B. F 检验和 t 检验的作用完全相同, 可以互换使用
- C. F 检验用于检验所有自变量的整体显著性, t 检验用于检验单个自变量的显著性
- D. F 检验只有在 t 检验结果不显著时才有必要使用

4. (难) 关于线性回归模型的说法中, 哪一项是错误的?

- A. 如果“残差与预测值”散点图中的残差并不是以 0 为均值分散, 而是呈现抛物线形状, 通常说明模型遗漏了重要的自变量或者应该考虑非线性模型
- B. 残差的 Q-Q 图两侧“尾巴”明显偏离直线, 说明残差与正态分布有一定的差距, 可以通过对数变换来进行改善
- C. 在进行多重共线性检验时, 可以通过计算方差膨胀因子 (VIF)。根据经验, 如果某个变量的 VIF 值超过 5 或者 10, 说明存在严重的共线性, 需要引起注意
- D. Cook 距离是用来检验模型是否存在异方差现象的重要指标。Cook 距离越大的样本, 说明该点处的异方差问题越严重

5. (中) 关于线性回归中的强影响点与 Cook 距离, 下列说法正确的是 ()

- A. Cook 距离是针对自变量计算的, 每个自变量对应一个 Cook 距离

- B. 强影响点是指包含/不包含该样本点时，对模型估计结果影响很大的样本点
- C. Cook 距离越大，说明该样本点对模型的影响越小
- D. 强影响点一定是异常值，必须直接从数据中删除
6. (难) 在北京市二手房房价的对数线性回归模型分析中，加入“城区 $\times$ 学区”交互项后，学区变量的主效应系数变为负值，以下对该结果的合理解释是 ()
- A. 学区房对房价的正向影响完全消失，非学区房房价更高
- B. 学区房的溢价效应需结合城区来看，基准城区的学区房溢价不显著甚至存在小幅负向影响
- C. 模型出现多重共线性，结果完全不可信
- D. 数据存在异常值，需直接删除交互项重新建模
7. (易) 在线性回归模型中，若存在完全多重共线性，以下哪种情况会发生？
- A. 回归系数估计值偏大
- B. 无法唯一估计出回归系数
- C. 判定系数 R^2 变为 0
- D. 模型的预测精度显著提高
8. (较难) 调整后的判决系数为 $R^2_{\text{adjusted}} = 1 - [(n-1)/(n-p-1)] \times (SSE/SST)$ ，其中 p 为自变量个数。关于该统计量，下列说法正确的是 ()
- A. 当增加一个不显著的变量时， R^2_{adjusted} 一定减小
- B. 对于同一组数据， R^2_{adjusted} 总是小于 R^2 ，但两者的差距会随样本量 n 增大而缩小
- C. R^2_{adjusted} 可用来比较不同因变量变换（如 y 与 $\log y$ ）的模型拟合效果
- D. R^2_{adjusted} 越接近 1，表明模型对未来观测的预测能力越强
9. (难) 设线性回归模型为 $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (XD) + \varepsilon$ ，其中 X 为连续型自变量， D 为取值为 0 或 1 的虚拟变量。下列说法中，正确的是 ()
- A. β_2 表示两组在所有 X 水平下的平均差异恒为 β_2
- B. β_1 表示 $D=1$ 组中 X 对 Y 的影响
- C. β_3 表示两组中 X 对 Y 的影响是否存在差异
- D. 如果 $\beta_2 < 0$ ，则 $D=1$ 组在任意 X 取值下都比 $D=0$ 组的 Y 更小
10. (难) 全模型： $\text{price} \sim \text{CATE} + \text{bedrooms} + \text{halls} + \text{area} + \text{floor} + \text{subway} + \text{school}$ ；简化模型： $\text{price} \sim \text{CATE} + \text{area} + \text{floor} + \text{school}$ 。关于如何在这两个模型中进行选择，以及评估模型好坏，结合模型整体评价与选择准则，下列说法中不正确的是哪一项？
- A. 如果直接比较模型 A 和模型 B 的普通判决系数，模型 A 的 R^2 一定大于或等于模型 B，因此不能仅依靠普通 R^2 越大越好来作为剔除 bedrooms 等变量的依据
- B. 如果使用调整后的判决系数来对比，它在公式中引入了样本量 n 和自变量个数 p 的惩罚机制，因此可以用来比较全模型和简化模型的好坏
- C. 如果使用 AIC 和 BIC 准则对模型进行选择，由于二手房数据集样本量极大 ($n > 16000$)， $\log(n)$ 远大于 2，因此 BIC 对保留冗余变量的惩罚力度比 AIC 更大
- D. 在 R 语言中，可以使用 `step()` 函数基于上述准则进行自动筛选。通常情况下，BIC 选出的最终模型保留的变量个数，会多于 AIC 选出的变量个数
11. (难) 关于线性回归模型，下列说法错误的是 ()
- A. F 检验用来检验所有变量中是否有变量对 Y 的影响是显著的
- B. 调整后的 R^2 可以用于不同模型之间的比较
- C. 一般认为 R^2 越大，模型拟合效果越好； R^2 大于 0.5 时说明模型有实际解释能力
- D. 对于有 k 个水平的离散型自变量，需要选择一个水平为基准组，其余水平构造 $k-1$ 个哑变量

12. (中) 以下关于对数线性回归模型 $\log(y)=\beta_0+\beta_1x_1+\dots+\epsilon$ 的说法, 正确的是 ()
- A. 若 x_1 为连续变量且回归系数 $\beta_1=-0.03$, 则 x_1 每增加一个单位, y 平均下降约 3%
 - B. 对数变换可以完全消除异方差问题
 - C. 对数线性模型要求 y 必须服从对数正态分布
 - D. 对数线性模型的残差可以直接用原始模型的残差图来诊断
13. (困难) 关于模型选择准则 AIC 和 BIC, 下列说法正确的是 ()
- A. 选择模型时, 应选取 AIC 或 BIC 值最大的模型
 - B. AIC 和 BIC 的第一项通常是残差平方和 (RSS) 的单调函数, 代表模型的拟合优度
 - C. 当样本量 $n \geq 8$ 时, AIC 对模型复杂度的惩罚力度比 BIC 更大
 - D. 相比 AIC, BIC 选出来的模型通常包含更多的自变量
14. (中) 在模型诊断时, 下列结果哪个是我们希望看见的?
- A. Q-Q 图散点明显偏离 $y=x$ 参考线
 - B. 残差以 0 为均值, 无规律散乱分布
 - C. 残差 vs 拟合值图从左向右残差波动不一致
 - D. Scale-Location 图红色趋势线不水平

填空题

共 10 题

1. (易) 在线性回归的显著性检验中, _____ 检验用于检验单个自变量对因变量的影响是否显著, _____ 检验用于检验所有自变量整体对因变量的影响是否显著。
2. (难) 在进行回归模型选择时, 常用的准则有赤池信息准则 (AIC) 和贝叶斯信息准则 (BIC)。这两种准则不仅考虑模型拟合优度, 还包含对模型复杂程度 (自变量个数 p) 的惩罚。根据公式, AIC 准则的惩罚项系数是 _____, BIC 准则的惩罚项系数是 _____ (填包含样本量 n 的数学公式)。当样本量 $n \geq 8$ 时, 由于 _____, BIC 比 AIC 的惩罚力度要大。因此, 往往 BIC 选出来的变量个数要 _____ (填“多于”或“少于”) AIC 选出来的变量个数。
3. 随着预测值的增大, 残差的波动也随之增大, 说明模型存在 () 现象。QQ 图的尾巴偏离直线, 说明残差和 () 分布有一定差距。对于以上诊断出的结果, 我们应该采用 () 线性回归的方法。
4. (易) 在建立线性回归模型时, 如果一个离散型自变量 (例如“所属城区”) 有 k 个水平, 在建模过程中通常需要选择其中一个水平作为基准组, 并为剩余的水平构造 _____ 个哑变量 (虚拟变量)。
5. (中) 在模型 $\ln(y)=\beta_0+\beta_1\ln(x)$ 中, 系数 β_1 表示 x 每变动 1%, y 平均变动 _____。
6. (中) 残差-预测值图像中, 残差并不以 0 为平均水平波动, 而是呈现出抛物线形状, 说明 _____; 如果残差呈现喇叭状, 说明出现了 _____ 现象, 需要通过 _____ 来改善。
7. (难) 在线性回归模型中, 方差膨胀因子 VIF 用于检验 _____ 问题, 通常 VIF 大于 _____ 时表示存在严重共线性; 在二手房案例中, 经检验最大 VIF 为 5, 说明该问题 _____。若存在多重共线性, 可以使用 _____ 方法解决。

8.

题干：样本量 $n = 35$ ，无约束模型含截距项 +4 个解释变量， $R_{ur}^2 = 0.78$ ；约束模型（2 个系数联合为 0） $R_r^2 = 0.72$ 。计算约束 F 统计量为_____（保留 2 位小数）；在 5% 水平下临界值为 3.29，则应_____原假设。

9.（易）请写出经典线性回归模型 $Y = X\beta + \varepsilon$ 下，对于随机误差项 ε 的假设：_____。

10.（中）在模型诊断中，若残差图（横轴为预测值，纵轴为残差）呈现出明显的“喇叭状”（即残差随预测值增大而波动增大），这通常意味着模型违反了随机误差项的_____假设；若要修正这一问题，可采用_____。