

数据科学实战：回归与方差分析、生存分析习题汇总

习题整合

2026 年 6 月 6 日

1 判断题

1. 在进行方差分析 (ANOVA) 时, 如果 F 检验的结果显著 (即 p 值小于显著性水平, 如 0.05), 这说明所有组的均值都不相等。
2. $AIC = -2\ln(L) + 2 \cdot df$; $BIC = -2\ln(L) + df \cdot \ln(n)$ 这里 L 是似然函数值, df 是自由度, n 为样本量; 且二者越小越好, 是用于评估模型; 两者都是由拟合优度项和固定复杂度惩罚项构成。
3. 在进行统计建模时, 如果因变量 Y 是定性数据 (例如: 消费者是否购买某产品/病人的诊断结果为“得病”或“未得病”), 我们通常可以直接使用经典的线性回归模型进行建模, 而不需要做任何特殊处理。
4. 在进行单因素方差分析时, 其核心思想是将数据的总变异 (SST) 拆分为组间变异 (SSR) 和组内变异 (SSE)。如果我们计算出的 F 统计量非常大, 通常意味着组内方差 (误差带来的波动) 显著超过了组间方差 (不同处理水平带来的波动), 因此我们没有充分的理由拒绝原假设 (即认为各组均值相等)。
5. 单因素方差分析中, 若 F 检验的 p 值小于 0.05, 说明该因素的所有水平之间均存在显著差异。
6. 在线性回归模型中, F 检验的原假设是“所有自变量的系数 (不包括截距) 都等于 0”。
7. 在生存分析中, AFT (加速失效时间) 模型和 Cox 比例风险模型对回归系数的解读方向是相同的: 若某个协变量在两个模型中的系数符号一致, 则说明该变量对生存时间的影响方向也一致。
8. 在线性回归模型中, 我们通常对随机误差项有以下三个假设: a. 零均值 b. 同方差 c. 无相关性。在这三个假设的基础上我们有时会进一步假设随机误差项符合正态分布。现在若回归模型的 QQ 图散点偏离直线, 这代表模型关于随机误差项同方差假设即出现异方差性。若回归模型的残差图呈现喇叭状, 这代表回归模型的随机误差项符合正态分布假设错误。出现这两个问题时, 对因变量进行对数变换均是一个不错的解决方案。
9. 调整后的判定系数 (调整 R^2) 与普通的判定系数 (R^2), 后者其计算值总是大于普通的 R^2 , 因此可以用来比较不同模型间的拟合效果。
10. 设某二分类问题的 logistic 回归模型为

$$\log \frac{p}{1-p} = -1 + 0.5x.$$

当 $x = 2$ 时, 若按照分类规则“当预测概率大于阈值 c 时判为 1, 否则判为 0”, 且取 $c = 0.5$, 则该样本会被判为 1。

11. 在北京市二手房数据分析中, 线性回归模型的残差图呈现“喇叭状”分布, 说明模型存在异方差问题。为了解决这一问题, 可以对因变量“单位面积房价”进行对数变换。
12. 方差分析是一种特殊的线性回归模型, 其自变量为分类变量, 因变量为连续型数值变量。
13. 在线性回归中, 如果残差图呈明显“喇叭口”形状, 说明模型可能存在异方差; 若因变量恒为正, 可考虑对因变量做对数变换后重新建模。
14. 在北京市二手房数据的线性回归分析中, 当对因变量“单位面积房价”取对数后建立对数线性回归模型, 此时, 自变量每增加一个单位, 因变量(单位面积房价)平均增加(系数 $\times 100$)个百分点。
15. (a) 单因素方差分析中, $SST = SSA + SSE$ 成立的前提是满足正态性, 可加性, 方差齐性三大假设。 $\checkmark$
(b) 对数线性模型 $\log(Y) = \beta_0 + \beta_1 X + \varepsilon$ 中, β_1 表示 X 每增加 1, Y 平均增加 β_1 个单位。 $\times$
(c) Cox 比例风险模型是半参数模型, 不需要假设基准风险函数的分布形式。 $\checkmark$
(d) 方差分析 F 检验显著后, 可直接判断哪两组之间存在显著差异。 $\times$
(e) $VIF > 10$ 通常认为变量间存在严重多重共线性。 $\checkmark$
16. 在北京市二手房案例中, 本案例所关心的因变量 Y 是“房屋总价”。
17. 在定序数据编码为 1、2、3、4 后, 因此这些数字之间可以像普通数值变量一样进行加减乘除运算。
18. 在方差分析中, 只要自变量是类别型变量、因变量是数值变量, 就一定不需要任何前提假设, 可以直接进行 ANOVA。
19. 在逻辑回归中, 如果某个解释变量的系数估计值为负, 那么在控制其他变量不变时, 该变量增加通常会降低 $Y = 1$ 的发生倾向。
20. 在完整数据分析流程中包含背景介绍、数据来源与说明、描述性分析、统计建模以及结论与建议等环节。
21. 在逻辑回归中, 若使用极大似然估计得到的系数满足渐近正态, 三种检验 (Wald、得分、似然比) 有限样本下 P 值完全相同。
22. 二手房回归中面积系数为负, 控制其他不变面积越大单位房价越低。
23. 在信用卡逾期数据分析案例中, 因变量“逾期状态”是包含 8 个水平的定序变量 $\square$ 建模策略: 先 01 回归判断是否逾期, 再对逾期样本做定序回归预测严重程度。

2 单项选择题

1. 在逻辑回归 (Logistic Regression) 中, 我们通常使用什么函数将线性回归的输出映射到 (0,1) 区间, 以表示概率?
- (a) ReLU 函数
- (b) Sigmoid 函数 (或 Logistic 函数)

- (c) Tanh 函数
- (d) Softmax 函数
2. 下列关于 ROC 曲线说法错误的是 ()
- (a) ROC 的横纵轴是分别是 FPR(Specificity) 和 TPR(Sensitivity)
- (b) $FPR = FP / (FP + TP)$, $TPR = TP / (TP + FN)$
- (c) ROC 曲线与横轴所围成的面积是 AUC
- (d) AUC 值越大预测效果越好
3. 在新产品在架时间的研究案例中, 分析师分别使用了 AFT 生存回归模型 (Weibull 分布) 和 Cox 生存回归模型对数据进行了拟合。关于这两个模型的估计系数及其解读, 根据讲义内容, 下列说法中不正确的一项是?
- (a) AFT 模型是对数线性模型的延伸, 它直接对生存时间建模。在 R 语言的 `survreg` 函数输出中, 若某个变量的系数为负值, 表示该因素会缩短产品的预期在架时间。
- (b) Cox 模型是对风险函数建模, 它不直接预测生存时间, 而是预测 “瞬时风险”。在 R `coxph` 输出中, 若某个变量的系数为正值, 表示该因素会增加产品下架的风险。
- (c) 在同一个案例中, 如果一个因素在 AFT 模型中的估计系数为负, 那么它在 Cox 模型中的估计系数符号通常也应该是负的。
- (d) AFT 需要假设生存分布, Cox 半参数不用约束基准风险 $h_0(t)$ 分布形式。
4. 在单因素方差分析中, 以下哪个说法是正确的?
- (a) 原假设是各总体的方差相等
- (b) $F = \frac{SSA/(a-1)}{SSE/(n-a)} \sim F(a-1, n-a)$
- (c) 若 F 值小于临界值, 说明因素对因变量有显著影响
- (d) 方差分析出不需要正态性假设
5. 关于 AUC, 下列说法中正确的是?
- (a) AUC 的取值大小会随着分类阈值 (Threshold) 的改变而发生变化。
- (b) AUC 值越接近 0.5, 说明该模型的分类预测效果越理想。
- (c) AUC 衡量的是模型在所有可能的分类阈值下的平均表现, 其取值与阈值的选取无关。
- (d) 当 AUC 等于 1 时, 说明模型对所有样本的预测结果与实际情况完全相反。
6. 逻辑回归 X 系数 =0.5, 下列正确的是
- (a) X+1, 概率 +50%
- (b) X+1, 发生比 +0.5
- (c) X+1, 对数发生比 +0.5
- (d) 系数无法解释
7. 关于各类回归与方差说法正确的是 ()

- (a) 进球计数用标准泊 (无过离散)
- (b) ANOVA 显著则全部组别均值不等
- (c) 定序回归用潜变量划分区间
- (d) LR 用最小二乘

8. 某研究开展两因素无重复方差, 已知:

变异来源	SS	df	MS	F
A	?	?	?	?
B	45	3	15	7.5
误差	12	6	2	-
总和	117	11		

$\alpha = 0.05, F_{0.05}(2, 6) =$

5.14, $F_{0.05}(3, 6) = 4.76$, 下列正确?

- (a) 总自由度计算错误
- (b) $F = \text{误差均方} / \text{因素均方}$
- (c) $F_A = 15 > 5.14$, 因素 A 显著
- (d) 满足泊松分布假设

3 填空题

1. Logistic Function 和 Logit Function 的区别
2. Log-rank $p=0.12$, Wilcoxon $p=0.01$, 差异集中在申请周期早期
3. 混淆矩阵: TP=90 FN=10 FP=20 TN=80, TPR=____, FPR=____
4. 生存无法观测确切失效时间叫____; 风险建模____; Cox 与 AFT 系数符号____
5. 双因素无重复 SST=____+____+____+SSE; 交互显著代表____; Cox: $h(t, X) = h_0(t)e^{\beta X}$, $h_0(t)$ 是____; Cox 半参数不用基准分布, AFT 参数需指定分布; 泊松: ____ 数据, 连接____, 过离散换____
6. 单因素 SST=____
7. 时长生存建模用____
模型解读: 核心理解 X-Y 关系; 预测: 精准预估未知 Y。
8. 在定序回归 (probit/logit) 中, 假设因变量 Y 有 5 个类别 (如产品满意度: 1= 非常不满意, 2= 不满意, 3= 一般, 4= 满意, 5= 非常满意)。潜变量

$$Z = \beta X + \varepsilon, \quad \varepsilon \sim N(0, 1).$$

则模型中需要估计的阈值参数 $(c_1, c_2, \dots)$ 的个数为 ____。

对于有 K 个类别的定序变量, 需要 $K - 1$ 个阈值将实数轴划分为 K 个区间。例如 $K = 5$ 时,

阈值 $c_1 < c_2 < c_3 < c_4$, 使得:

$$Y = 1, \quad \text{若 } Z < c_1;$$

$$Y = 2, \quad \text{若 } c_1 \leq Z < c_2;$$

$$Y = 3, \quad \text{若 } c_2 \leq Z < c_3;$$

$$Y = 4, \quad \text{若 } c_3 \leq Z < c_4;$$

$$Y = 5, \quad \text{若 } c_4 \leq Z.$$

因此阈值个数为 $K - 1 = 4$ 。

9. $\log \frac{p}{1-p} = \log 3$, odds = ____, $p =$ ____

10. 生存非参数____; 组间检验____; Cox 风险比不随____ 变。

11. $SST =$ ____ + ____; $df_T = n - 1 =$ ____ + ____; $F = \frac{SSA/(a-1)}{SSE/(n-a)}$