

数据科学实战分类模型习题汇总

(朴素贝叶斯、决策树、随机森林、XGBoost)

习题整合

2026 年 6 月 6 日

1 判断题

1. 随机森林的训练集抽样方式是 bootstrap 抽样, 这是一种无放回随机抽样。
2. 朴素贝叶斯算法之所以被称为“朴素”, 是因为它在进行概率计算时, 做出了一个理想化的假设: 即所有的特征之间都是相互独立的, 不存在任何相关性。
3. 随机森林通过 Bootstrap 重抽样和随机特征选择降低树之间的相关性, 这主要降低了模型的偏差; 而 XGBoost 通过逐轮迭代拟合残差, 主要降低了模型的方差。
4. 在政府热线平台案例中, 投诉文本经过中文分词后可以转化为“样本 $\times$ 词语”的数值矩阵; 由于大多数投诉只包含少量词语, 这类矩阵通常包含大量 0, 属于高维稀疏矩阵。
5. 决策树越深, 分支越细, 说明模型越复杂, 对训练数据拟合越好, 因此一定能在测试集上取得更好的预测效果。
6. 朴素贝叶斯分类器的“朴素”是指它假设所有特征之间相互独立。
7. 高斯混合模型 (GMM) 是判别式模型。
8. 朴素贝叶斯分类器的“属性独立性假设”是指所有属性之间全局相互独立。
9. 信息增益对可取值数目较多的属性有偏好, 而增益率对可取值数目较少的属性有偏好。
10. 在 12345 政府热线投诉文本分类中, 分词后的数值矩阵行是投诉、列是词语, 多数元素为 0, 稀疏矩阵。
11. 在朴素贝叶斯分类器中, 如果某个特征在训练集的某一类别下从未出现, 则测试时该类别对应的后验概率一定会变为 0, 无论其他特征如何取值。
12. 在朴素贝叶斯分类器中, “朴素”指的是假设所有特征在给定类别的条件下相互独立。

2 单项选择题

1. 关于决策树预剪枝与后剪枝描述错误的是 ()
 - (a) 预剪枝为提前终止某些分支的生长
 - (b) 后剪枝为生成一棵完全树, 再“回头”剪枝

- (c) 预剪枝更容易引发欠拟合, 后剪枝泛化效果通常更优
- (d) 后剪枝训练耗时少于预剪枝
2. 下列属于生成式模型的为 ()
- (a) 决策树
- (b) 朴素贝叶斯分类器
- (c) SVM
- (d) 逻辑回归
3. 关于分类器模型特点说法正确的是 ()
- (a) 朴素贝叶斯属于判别式, 直接建 $P(c|x)$
- (b) 决策树属于生成式, 建联合 $P(x, c)$
- (c) 朴素贝叶斯条件独立假设现实难成立, 但文本分类表现优良
- (d) 随机森林属于 Boosting, 串行迭代修正残差
4. ID3 按信息增益选特征, 数据: 色泽 0.109、根蒂 0.143、敲声 0.141、纹理 0.381, 最优划分?
- (a) 色泽
- (b) 根蒂
- (c) 敲声
- (d) 纹理
5. 决策树剪枝正确说法 ()
- (a) 预剪枝在全树生成后修剪
- (b) 后剪枝生长中提前停止分支
- (c) 预剪枝在生长时判断泛化收益, 无效则停止划分
- (d) 剪枝只会降低模型效果
6. 衡量集合纯度、数值越小纯度越高 ()
- (a) 信息熵
- (b) 准确率
- (c) 精确率
- (d) 召回率
7. 天生适配高维稀疏文本、训练快、小样本可用 ()
- (a) 朴素贝叶斯
- (b) 深度神经网络
- (c) SVM
- (d) 普通线性回归

8. 说法错误 ()
- (a) 朴素贝叶斯生成式
 - (b) LR 判别式
 - (c) 高斯核 SVM 生成式
 - (d) HMM 生成式
9. 自助抽样 OOB 占比 ()
- (a) 50.0%
 - (b) 36.8%
 - (c) 25.0%
 - (d) 63.2%
10. 随机森林描述不正确 ()
- (a) Bootstrap 有放回采样
 - (b) 样本 + 特征双重随机
 - (c) OOB 样本无使用价值直接丢弃
 - (d) OOB 可评估特征重要性
11. 预剪枝后剪枝正确 ()
- (a) 预剪枝生成全树再剪
 - (b) 后剪枝训练开销大，泛化普遍优于预剪枝
 - (c) 预剪枝易过拟合
 - (d) 后剪枝彻底消除过拟合
12. XGB 与半朴素贝叶斯错误描述 ()
- (a) ODE 每个特征至多依赖一个其他特征
 - (b) XGB 正则惩罚叶子数与叶权重
 - (c) XGB 穷举叶子权重寻最优分裂
 - (d) XGB 学习率、列采样防过拟合
13. 随机森林抗过拟合核心原因 ()
- (a) 梯度下降全局寻优
 - (b) 样本 + 特征双重随机集成投票
 - (c) 逐棵拟合残差
 - (d) 树深度固定为 1
14. Bagging 与 Boosting 错误描述 ()
- (a) Bagging 并行降方差

- (b) Boosting 串行降偏差
 - (c) OOB 约 36.8%
 - (d) 随机森林仅样本随机、特征全取
15. 决策树划分与剪枝正确 ()
- (a) C4.5 无条件选增益率最大特征
 - (b) CART 选基尼指数最大特征
 - (c) 预剪枝无效则停止划分、节省训练时间
 - (d) 后剪枝预测耗时大于未剪枝树
16. 12345 热线朴素贝叶斯说法正确 ()
- (a) 效果好因为特征满足独立假设
 - (b) 原始词频直接入 naiveBayes 会被拟合成正态、效果极差
 - (c) 拉普拉斯平滑一定提升准确率
 - (d) 词频二值化目的降维度
17. 剪枝错误描述 ()
- (a) 全树训练 100%、验证 42.9% 典型过拟合
 - (b) 预剪枝权衡偏差方差
 - (c) 后剪枝泛化优于预剪枝
 - (d) 验证集比例越大泛化一定越好
18. 四种算法正确 ()
- (a) 准确率高代表算法全局最优
 - (b) 随机森林双重随机降低偏差
 - (c) XGB 正则惩罚叶子数量与叶权重
 - (d) 随机森林可解释性优于单决策树
19. 朴素贝叶斯零概率解决方案 ()
- (a) 加样本
 - (b) 删属性
 - (c) 拉普拉斯修正
 - (d) 交叉验证
20. 热线文本朴素贝叶斯正确 ()
- (a) 独立假设不成立因此不能用文本分类
 - (b) 零概率可用拉普拉斯修正
 - (c) 朴素贝叶斯判别式模型

(d) 词频直接连续输入无负面影响

21. 拉普拉斯修正作用 ()

- (a) 提升准确率
- (b) 统一全部概率
- (c) 规避零概率失效
- (d) 连续离散转换

22. ODE 独依赖估计定义 ()

- (a) 全部特征两两依赖
- (b) 每个特征除类别至多依赖一个特征
- (c) 忽略离散属性
- (d) 全特征互相依赖

23. ID3 选特征依据 ()

- (a) 信息增益最大
- (b) 熵最大
- (c) 基尼最大
- (d) 属性最少

24. 热线词频朴素贝叶斯合理处理 ()

- (a) 直接当作正态连续
- (b) 词频转为 0/1 二值因子
- (c) 文本不能用朴素贝叶斯
- (d) 词频越大越准

25. 增益描述正确 ()

- (a) 增益偏好多取值，增益率也偏好多取值
- (b) 增益偏好少取值
- (c) 增益偏多、增益率易偏少
- (d) 二者等价

26. ROC 绘制正确 ()

- (a) 固定阈值描单点
- (b) 类别概率做阈值遍历画曲线
- (c) 朴素贝叶斯不能输出概率
- (d) 多分类无法 ROC

27. TAN 树增强朴素贝叶斯正确 ()

- (a) 全特征依赖同一超父
- (b) 最大带权生成树构造依赖
- (c) 复杂度低于朴素贝叶斯
- (d) 无特征依赖

28. 树与集成学习正确 ()

- (a) 熵越大纯度越高
- (b) 随机森林只样本随机
- (c) Bagging 并行、Boosting 串行
- (d) XGB 无正则

29. 信息增益公式选择题

- (a) $H(D) - \frac{1}{2}H(D_1) - \frac{1}{2}H(D_2)$
- (b) $H(D) - \frac{5}{10}H(D_1) - \frac{5}{10}H(D_2)$
- (c) $H(D_1) + H(D_2) - H(D)$
- (d) $\frac{5}{10}H(D_1) + \frac{5}{10}H(D_2) - H(D)$

3 填空题

1. 朴素贝叶斯 “朴素”：给定类别，特征_____。
2. CART 分类树最小化_____。
3. 朴素贝叶斯基本假设：_____。
4. ID3：_____；C4.5：_____；CART：_____；随机森林二重随机：_____、_____。
5. Bootstrap 极限不采样占比：_____%；XGB 正则 $\Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2$ ： $T=$ _____, $w=$ _____。
6. Bagging 基学习器_____；Boosting_____；拉普拉斯假设特征类别_____ 分布，引入_____。
7. 零概率用_____ 修正；Bagging 采用_____ 抽样；树全生成后自底向上剪枝：_____；召回率：正例预测正确占比。
8. ID3：信息增益，C4.5 增益率，CART 基尼指数；预剪枝生长中停止，后剪枝全树再修剪。
9. 随机森林_____ 并行；XGBoost_____ 串行，逐轮拟合_____。
10. $D = 10, N = 3, c = 4$ ，漏水在 c 下出现 0 次，特征取值 $N_i = 2$
 - $\hat{P}(c) =$ _____
 - $\hat{P}(x = 1|c) =$ _____
11. _____ 剪枝提前终止分支，易_____；_____ 剪枝全树再修剪；验证集采用_____ 法。
12. $Ent(D) = 0.971$, $D_1(6) : Ent = 0.650$, $D_2(4) : Ent = 0.811$, $Gain =$ _____。

13. 生长中提前停止：_____；全树生成再修剪：_____。
14. RF 双重随机：_____、_____；无验证集评估：_____。
15. $P(y = 1|x_1, x_2) \propto$ _____。

4 简答/综合应用题

1. 随机森林优缺点（各两点）
2. 假设你正在为某市的“12345 政府热线”开发一个预测模型，任务是根据工单的结构化属性，例如：来电时间、诉求分类、紧急程度、区域代码等，对该工单的处理时长进行预测。团队目前在使用基于决策树的模型（如 XGBoost、LightGBM 等集成树）以及使用神经网络中产生分歧。请从以下三个维度对比两者，并给出你的首选推荐以及理由：
 1. 计算资源与训练速度
 2. 对异常值的鲁棒性
 3. 向非技术领导汇报时的沟通成本（模型可解释性）