

数据科学实战作业反馈习题汇总

2026 年 6 月

1 判断题

- 在进行回归分析时，如果模型显示自变量X（如：是否临近地铁）对因变量Y（单位面积房价）的影响在统计学上显著，则可以判定X是导致Y变化的因果原因。
- 在二手房数据集中，我们发现不同地区的房价差异巨大，比如：西城某学区房，单价约13.5万/平米；石景山某非学区房，单价约3.6万/平米。针对上述数据中存在的极值拉高平均水平现象，我们将模型改进为对数线性模型： $\log(y) = \beta_0 + \beta_1 x_1 + \dots + \epsilon$ 。假设我们在对数线性模型中，计算出 school（是否为学区房，1代表是，0代表否）这一自变量的系数估计值为 0.171。那么我们是否可以解读为：“在控制其他因素不变时，学区房单位面积房价比非学区房平均高出 0.171 万元/平方米”。
- 在分析某城市共享单车骑行时长分布时，如果直方图显示数据右偏，则可以判断大多数用户骑行时间较长。
- 在线性模型中，QQ 图常用于检验自变量对因变量是否具有显著影响。（ ）
- 在进行方差分析(ANOVA)时,如果F检验的结果显著(即p值小于显著性水平,如0.05),这说明所有组的均值都不相等。
- 在进行统计建模时,如果因变量Y是定性数据(例如:消费者是否购买某产品;病人的诊断结果为“得病”或“未得病”),我们通常可以直接使用经典的线性回归模型进行建模,而不需要做任何特殊处理。
- 在生存分析中,AFT(加速失效时间)模型和Cox比例风险模型对回归系数的解读方向是相同的:若某个协变量在两个模型中的系数符号一致,则说明该变量对生存时间的影响方向也一致。
- 单因素方差分析中, $SST=SSA+SSE$ 成立的前提是满足正态性,可加性,方差齐性三大假设。
- Cox比例风险模型是半参数模型,不需要假设基准风险函数的分布形式。
- 方差分析F检验显著后,可直接判断哪两组之间存在显著差异。
- 在定序数据编码为1、2、3、4后,因此这些数字之间可以像普通数值变量一样进行加减乘除运算。
- 在逻辑回归中,如果某个解释变量的系数估计值为负,那么在控制其他变量不变时,该变量增加通常会降低Y=1的发生倾向。

- 在逻辑回归中,若使用极大似然估计得到的系数满足渐近正态,三种检验(Wald、得分、似然比)有限样本下P值完全相同。
- 在信用卡逾期数据分析案例中,因变量“逾期状态”是包含8个水平的定序变量。建模策略:先使用01回归判断是否逾期,再对逾期样本做定序回归预测严重程度。
- 在学生成绩主成分分析中,若前两个主成分的累积贡献率超过 80%,就说明这两个综合指标已经完整保留了原来六门课的全部信息,因此不需要再解释载荷含义。
- 因子分析中,因子及其载荷矩阵的估计不是唯一的,可以通过任意正交矩阵进行旋转,以寻找使因子结构更简单、解释更清晰的旋转方向。
- 聚类分析 (Clustering Analysis) 属于一种有监督学习方法,需要样本提前带有类别标签。
- 在 K-Means聚类算法中,由于采用了迭代优化的思想,因此只要初始中心点选择得当,算法一定能收敛到全局最优解,而不会陷入局部最优。()
- K-Means算法的核心是最小化各个簇内的样本到质心的欧氏距离平方和,因此该算法在处理非凸形状(如环状、月牙形分布)的数据簇时,依然能够准确地将不同形状的数据有效分离。
- 聚类分析 (Clustering Analysis)、主成分分析 (PCA) 以及因子分析 (Factor Analysis) 在建立模型时都没有事先确定的因变量,因此它们都属于无监督的统计学习方法。
- 朴素贝叶斯算法之所以被称为“朴素”,是因为它在进行概率计算时,做出了一个理想化的假设: 即所有的特征之间都是相互独立的,不存在任何相关性。
- 随机森林通过 Bootstrap 重抽样和随机特征选择降低树之间的相关性,这主要降低了模型的偏差;而 XGBoost 通过逐轮迭代拟合残差,主要降低了模型的方差。
- 在政府热线平台案例中,投诉文本经过中文分词后可以转化为“样本×词语”的数值矩阵;由于大多数投诉只包含少量词语,这类矩阵通常包含大量 0,属于高维稀疏矩阵。
- 决策树越深,分支越细,说明模型越复杂,对训练数据拟合越好,因此一定能在测试集上取得更好的预测效果。
- 高斯混合模型 (GMM) 是判别式模型。
- 信息增益对可取值数目较多的属性有偏好,而增益率对可取值数目较少的属性有偏好。
- 在12345政府热线投诉文本分类中,分词后的数值矩阵行是投诉、列是词语,多数元素为 0,属于稀疏矩阵。
- 在朴素贝叶斯分类器中,如果某个特征在训练集的某一类别下从未出现,则测试时该类别对应的后验概率一定会变为0,无论其他特征如何取值。

2 单项选择题

- 下列关于线性回归模型诊断与优化的说法中，错误的一项是（ ）
- A. 残差图呈现明显的喇叭状，是模型存在异方差问题的典型特征
 - B. 对因变量做对数变换，可改善模型的异方差问题与残差非正态问题
 - C. 自变量的方差膨胀因子为6.2，说明该变量存在严重的多重共线性，须从模型中剔除
 - D. Cook 距离用于识别样本中的强影响点，判断单个样本对模型拟合结果的影响程度
- 关于线性回归模型中的F 检验和t 检验，下列说法正确的是（ ）
- A. F 检验用于检验单个自变量的显著性，t 检验用于检验所有自变量的整体显著性
 - B. F 检验和t 检验的作用完全相同，可以互换使用
 - C. F 检验用于检验所有自变量的整体显著性，t 检验用于检验单个自变量的显著性
 - D. F 检验只有在t 检验结果不显著时才有必要使用
- 关于线性回归模型的说法中，哪一项是错误的？
- A. 如果“残差与预测值”散点图中的残差并不是以0 为均值分散，而是呈现抛物线形状，通常说明模型遗漏了重要的自变量或者应该考虑非线性模型
 - B. 残差的Q-Q 图两侧“尾巴”明显偏离直线，说明残差与正态分布有一定的差距，可以通过对数变换来进行改善
 - C. 在进行多重共线性检验时，可以通过计算方差膨胀因子（VIF）。根据经验，如果某个变量的VIF 值超过10，说明存在严重的共线性，需要引起注意
 - D. Cook 距离是用来检验模型是否存在异方差现象的重要指标。Cook 距离越大的样本，说明该点处的异方差问题越严重
- 在北京市二手房房价的对数线性回归模型分析中，加入“城区× 学区”交互项后，学区变量的主效应系数变为负值，以下对该结果的合理解释是（ ）
- A. 学区房对房价的正向影响完全消失，非学区房房价更高
 - B. 学区房的溢价效应需结合城区来看，基准城区的学区房溢价不显著甚至存在小幅负向影响
 - C. 模型出现多重共线性，结果完全不可信
 - D. 数据存在异常值，需直接删除交互项重新建模
- 在线性回归模型中，若存在完全多重共线性，以下哪种情况会发生？
- A. 回归系数估计值偏大
 - B. 无法唯一估计出回归系数
 - C. 判定系数 R^2 变为0
 - D. 模型的预测精度显著提高
- 全模型： $\text{price} \sim \text{CATE} + \text{bedrooms} + \text{halls} + \text{area} + \text{floor} + \text{subway} + \text{school}$ ；简化模型： $\text{price} \sim \text{CATE} + \text{area} + \text{floor} + \text{school}$ 。关于如何在这两个模型中进行选择，以及评估模型好坏，结合模型整体评价与选择准则，下列说法中不正确的是哪一项？
- A. 如果直接比较模型A 和模型B 的普通判决系数，模型A 的 R^2 一定大于或等于模型B，因此不能仅依靠普通 R^2 越大越好来作为剔除bedrooms 等变量的依据
 - B. 如果使用调整后的判决系数来对比，它在公式中引入了样本量n 和自变量个数p 的惩罚机制，因此可以用来比较全模型和简化模型的好坏
 - C. 如果使用AIC 和BIC 准则对模型进行选择，由于二手房数据集样本量极大（ $n > 16000$ ）， $\log(n)$ 远大于2，因此BIC 对保留冗余变量的惩罚力度比AIC 更大
 - D. 在R 语言中，可以使用step() 函数基于上述准则进行自动筛选。通常情况下，BIC 选出的最终模型保留的变量个数，会多于AIC 选出的变量个数

➤ 关于线性回归模型，下列说法错误的是（ ）

- A. F 检验用来检验所有变量中是否有变量对Y 的影响是显著的
- B. 调整后的 R^2 可以用于不同模型之间的比较
- C. 一般认为 R^2 越大，模型拟合效果越好； R^2 大于0.5 时说明模型有实际解释能力
- D. 对于有k 个水平的离散型自变量，需要选择一个水平为基准组，其余水平构造k-1 个哑变量

➤ 以下关于对数线性回归模型 $\log(y)=\beta_0+\beta_1x_1+\dots+\varepsilon$ 的说法，正确的是（ ）

- A. 若 x_1 为连续变量且回归系数 $\beta_1=-0.03$ ，则 x_1 每增加一个单位，y 平均下降约3%
- B. 对数变换可以完全消除异方差问题
- C. 对数线性模型要求y 必须服从对数正态分布
- D. 对数线性模型的残差可以直接用原始模型的残差图来诊断

➤ 关于模型选择准则AIC 和BIC，下列说法正确的是（ ）

- A. 选择模型时，应选取AIC 或BIC 值最大的模型
- B. AIC 和BIC 的第一项通常是残差平方和（RSS）的单调函数，代表模型的拟合优度
- C. 当样本量 $n \geq 8$ 时，AIC 对模型复杂度的惩罚力度比BIC 更大
- D. 相比AIC，BIC 选出来的模型通常包含更多的自变量

➤ 在模型诊断时，下列结果哪个是我们希望看见的？

- A. Q-Q 图散点明显偏离 $y=x$ 参考线
- B. 残差以0 为均值，无规律散乱分布
- C. 残差vs 拟合值图从左向右残差波动不一致
- D. Scale-Location 图红色趋势线不水平

➤ 下列关于ROC曲线说法错误的是()

- (a) ROC的横纵轴是分别是FPR(Specificity)和TPR(Sensitivity)
- (b) $FPR=FP/(FP+TP)$, $TPR=TP/(TP+FN)$
- (c) ROC曲线与横轴所围成的面积是AUC
- (d) AUC值越大预测效果越好

➤ 在新产品在架时间的研究案例中,分析师分别使用了AFT生存回归模型(Weibull分布)和Cox生存回归模型对数据进行了拟合。关于这两个模型的估计系数及其解读,根据讲义内容,下列说法中不正确的一项是？

- (a) AFT模型是对数线性模型的延伸,它直接对生存时间建模。在R语言的survreg函数输出中,若某个变量的系数为负值,表示该因素会缩短产品的预期在架时间。
- (b) Cox模型是对风险函数建模,它不直接预测生存时间,而是预测“瞬时风险”。在Rcoxph输出中,若某个变量的系数为正值,表示该因素会增加产品下架的风险。
- (c) 在同一个案例中,如果一个因素在AFT模型中的估计系数为负,那么它在Cox模型中的估计系数符号通常也应该是负的。
- (d) AFT需要假设生存分布,Cox半参数不用约束基准风险 $h_0(t)$ 分布形式。

➤ 关于各类回归与方差说法正确的是()

- (a) 进球计数用标准泊(无过离散) (b) ANOVA显著则全部组别均值不等
(c) 定序回归用潜变量划分区间 (d) LR用最小二乘

➤

某研究开展两因素无重复方差, 已知:

变异来源	SS	df	MS	F
A	?	?	?	?
B	45	3	15	7.5
误差	12	6	2	-
总和	117	11		

$\alpha = 0.05, F_{0.05}(2, 6) =$

5.14, $F_{0.05}(3, 6) = 4.76$, 下列正确?

- (a) 总自由度计算错误
(b) $F = \text{误差均方} / \text{因素均方}$
(c) $F_A = 15 > 5.14$, 因素 A 显著
(d) 满足泊松分布假设

➤ 在聚类建模前, 通常需要对变量进行标准化。最主要原因是 ()。

- A. 标准化可以自动消除异常值
B. 标准化可以防止取值范围大的变量在距离计算中占据过大影响
C. 标准化可以让聚类问题变成分类问题
D. 标准化后类别数 K 就不需要再选择

➤ 关于 K-Means 聚类, 下列说法错误的是 ()

- A. 需要预先指定聚类数量 K
B. 对异常值比较敏感
C. 属于层次聚类方法
D. 可通过 WGSS 碎石图选择最优 K

➤ 关于 K-means 聚类, 下列说法错误的是哪一项?

- A. 需要先指定聚类个数 K。
B. 算法会反复执行“分配到最近中心点”和“更新中心点均值”。
C. K-means 对离群点不敏感, 并且特别适合 U 型、环状等非凸聚类。
D. nstart=20 表示用 20 组不同随机初始质心运行, 并选择 WGSS 最小的结果。

➤ 关于层次聚类与 K 均值聚类, 下列说法正确的是 ()。

- A. 层次聚类必须在开始前指定类别数 K, 且每个观测值初始随机分到 K 类中。
B. K 均值聚类不需要事先确定类别数 K, 并且通常用系统树图展示聚类路径。
C. 层次聚类可以从“每个观测值自成一类”开始逐步合并, 结果常用系统树图表示; K 均值聚类通常需要先确定类别数 K。
D. K 均值聚类对离群点不敏感, 因此特别适合存在大量异常值的数据。

➤ 关于主成分分析 (PCA) 与因子分析 (FA), 下列说法正确的是 ()。

- A. PCA 寻找原始变量的线性组合, 使得到的主成分方差尽可能大, 并且不同主成分之间互不相关。
B. PCA 中所有变量被等同对待, 没有自变量与因变量之分, 因此也属于无监督学习思路。

- C. FA 的目标之一是用少数不可观测的公共因子解释原始变量之间的相关性，因子载荷反映公共因子对变量的解释力。
- D. FA 中公共因子的个数必须等于原始变量个数，否则无法起到解释变量相关性的作用。
- E. PCA 与 FA 完全相同，二者都只是把变量压缩成更少的指标，不涉及任何模型或潜变量解释。

➤ 在因子分析中，为了让因子及载荷结构更简单、解释更清晰，常使用最大方差法（Varimax method）进行正交旋转。关于该旋转操作几何与代数特性的描述，以下正确的是？

- A. 旋转后，各原始变量的共同度会发生改变以适应新的因子。
- B. 旋转后，样本点在因子空间中的相对位置和彼此间的几何距离会发生拉伸或缩放。
- C. 旋转后，各个坐标轴之间的垂直（正交）关系会被打破，因子之间变为相关。
- D. 旋转仅仅改变了参考坐标系的朝向，点距、夹角和共同度均维持原状。

➤ 主成分分析与因子分析是数据科学中两种极其重要的降维技术。关于这两种算法的核心区别与物理机制，以下表述不正确的是哪一项？

- A. PCA 的核心目标是数据压缩与降维，它通过正交变换，将一组可能存在相关性的原始变量，转换为 一组线性不相关的新变量（主成分）。
- B. 在提取主成分时，第一主成分提取了原始数据中最大的方差（即保留了最多的原始信息）。
- C. 在进行 PCA 或因子分析之前，通常必须对原始连续数据进行标准化处理（Z-score），以消除不同变量之间量纲和数量级差异带来的偏差。
- D. 主成分分析与因子分析在数学模型上是完全等价的：两者都假设观测变量是由少数几个潜在的、不可观测的“公共因子”加上特殊误差项构成的。

➤ 题目：某研究者对学生六科成绩做因子分析（主成分法，2 个因子，未旋转），得到前两个因子的载荷矩阵近似为：

变量	Factor1	Factor2
数学	-0.79	0.42
物理	-0.73	0.40
化学	-0.64	0.63
语文	0.89	0.31
历史	0.81	0.47
英语	0.83	0.46

之后采用 最大方差法（Varimax）进行正交旋转，得到旋转后的载荷矩阵。关于旋转前后的变化，下列说法正确的是（）

- a) 旋转会改变每个变量的共同度
- b) 旋转后因子之间的夹角不再为 90° ，因此称为斜交旋转
- c) 旋转使每个因子上的载荷向 0 或 ± 1 极端化，从而更容易解释因子含义
- d) 旋转后的载荷矩阵等于原始载荷矩阵乘以一个正交矩阵，该正交矩阵由数据唯一确定，不依赖于旋转目标

➤ 某保险公司基于车联网数据开展驾驶行为风险评估，计划先对 14 项行驶指标（行驶里程、平均时速、转速标准差、疲劳驾驶时长等）进行降维，再根据降维结果将驾驶员分不同风险等级。下列关于该分析流程的表述，错误的是（）

- A. 可先采用因子分析将 14 项指标降维为行驶强度、行驶速度、出行习惯 3 个公共因子，提取因子得分后再进行 K-means 聚类
- B. 在聚类分析前必须对原始指标或因子得分进行标准化，否则量纲较大的变量会主导聚类结果
- C. 确定 K-means 聚类数时，可通过绘制 WGSS（组内平方和）碎石图，选择曲线下降最平缓处的K值作最优聚类数
- D. 若采用层次聚类进行对比分析，可使用 Ward 法（离差平方和法）计算类间距离，该方法通过最小化类内离差平方和的增量来合并类

- 在进行主成分分析（PCA）之前，通常需要对原始数据进行标准化。如果跳过标准化步骤直接对原始数据进行 PCA 计算，最可能导致以下哪种结果？
- 算法无法求解协方差矩阵的特征值与特征向量
 - 绝对数值（方差）较大的特征变量将主导主成分的方向，掩盖其他特征的有效信息
 - 主成分之间将不再满足正交性（相互独立）的假设
 - 算法提取出的第一主成分将解释 100% 的数据变异性

从协方差结构与统计建模的底层原理来看，关于主成分分析（PCA）与因子分析（FA）的数学本质对比，下列说法正确的是：

- 因子分析假定原始变量的总体协方差阵 Σ 可以精确分解为 $\Lambda\Lambda' + \Psi$ ，其中矩阵 Ψ 为对角阵，这意味着因子分析不仅试图解释变量间的相关性，还假设原始变量间的所有协方差只能由公共因子（即 $\Lambda\Lambda'$ 部分）来解释。
- 主成分分析与因子分析在数学上都可以看作是对原始变量协方差阵进行特征值分解的过程，因此在相同的数据集上，前 m 个主成分所代表的特征向量空间，与因子分析提取出的 m 个公共因子的载荷矩阵空间是等价的。
- 在主成分分析的模型中，由于主成分是原始变量的线性组合，因此当我们在模型中增加或减少原始变量的数量时，原有的第一主成分 Y_1 在各个样本上的得分数值以及其权重系数向量会保持绝对不变。
- 因子分析中由于引入了不可观测的公共因子，其参数估计存在“因子旋转不唯一性”，而最大方差法（Varimax）正交旋转通过最大化载荷矩阵中每行元素的平方方差，牺牲因子之间的正交独立性，换了解释性。

题目：在主成分分析（PCA）中，求解第一主成分的本质是一个优化问题。假设数据矩阵 $\mathbf{Y}$ 已中心化，以下哪个选项正确描述了求解第一主成分载荷向量 $\mathbf{a}_1$ 的总体层面优化目标和约束条件？

- $\max_{\mathbf{a}_1} \{\text{Var}(\mathbf{a}_1^T \mathbf{Y})\} \quad \text{s.t. } \|\mathbf{a}_1\|^2 = 1$
- $\min_{\mathbf{a}_1} \{\text{Var}(\mathbf{a}_1^T \mathbf{Y})\} \quad \text{s.t. } \|\mathbf{a}_1\|^2 = 1$
- $\max_{\mathbf{a}_1} \{\text{Var}(\mathbf{a}_1^T \mathbf{Y})\} \quad \text{s.t. } \mathbf{a}_1^T \mathbf{a}_2 = 0$
- $\min_{\mathbf{a}_1} \{\text{Var}(\mathbf{a}_1^T \mathbf{Y})\} \quad \text{s.t. } \mathbf{a}_1^T \mathbf{a}_2 = 0$

- 某 APP 收集了用户的“浏览时长、收藏数、下单金额、搜索频率、退款次数、客服咨询次数”等变量。研究者发现很多变量之间相关性很强，并怀疑背后存在“购买意愿”“售后风险”等不能直接观测的潜在维度。此时更适合优先考虑：

- 分类分析
- 因子分析
- 单纯求每个变量平均数
- 删除所有相关性高的变量

- 某研究者对 100 名消费者做聚类分析，变量包括：年消费金额（单位：元）、年购物次数（次）、是否购买会员（0/1）。结果发现聚类几乎完全由“消费金额”决定。最可能的原因是：

- 聚类方法错误
- 存在异常值
- 未进行标准化处理
- 样本量太小

- 下列属于生成式模型的为（ ）

(a) 决策树

- (b) 朴素贝叶斯分类器
- (c) SVM
- (d) 逻辑回归
- 关于分类器模型特点说法正确的是 ()
 - (a) 朴素贝叶斯属于判别式，直接建 $P(c|x)$
 - (b) 决策树属于生成式，建联合 $P(x, c)$
 - (c) 朴素贝叶斯条件独立假设现实难成立，但文本分类表现优良
 - (d) 随机森林属于 Boosting，串行迭代修正残差
- ID3按信息增益选特征，数据：色泽0.109、根蒂0.143、敲声0.141、纹理0.381，最优划分？
 - (a) 色泽 (b) 根蒂 (c) 敲声 (d) 纹理
- 说法错误 ()
 - (a) 朴素贝叶斯生成式
 - (b) LR 判别式
 - (c) 高斯核 SVM 生成式
 - (d) HMM 生成式
- 随机森林描述不正确 ()
 - (a) Bootstrap 有放回采样
 - (b) 样本 + 特征双重随机
 - (c) OOB 样本无使用价值直接丢弃
 - (d) OOB 可评估特征重要性
- 预剪枝后剪枝正确 ()
 - (a) 预剪枝生成全树再剪
 - (b) 后剪枝训练开销大，泛化普遍优于预剪枝
 - (c) 预剪枝易过拟合
 - (d) 后剪枝彻底消除过拟合
- 随机森林抗过拟合核心原因 ()
 - (a) 梯度下降全局寻优
 - (b) 样本 + 特征双重随机集成投票
 - (c) 逐棵拟合残差
 - (d) 树深度固定为 1
- Bagging 与 Boosting 错误描述 ()
 - (a) Bagging 并行降方差

- (b) Boosting 串行降偏差
 - (c) OOB 约 36.8%
 - (d) 随机森林仅样本随机、特征全取
- 12345 热线朴素贝叶斯说法正确 ()
 - (a) 效果好因为特征满足独立假设
 - (b) 原始词频直接入 naiveBayes 会被拟合成正态、效果极差
 - (c) 拉普拉斯平滑一定提升准确率
 - (d) 词频二值化目的降维度
- 市长热线文本的朴素贝叶斯分类，正确的是 ()
 - (a) 独立假设不成立因此不能用文本分类
 - (b) 零概率可用拉普拉斯修正
 - (c) 朴素贝叶斯判别式模型
 - (d) 词频直接连续输入无负面影响
- 关于ROC曲线的绘制正确 ()
 - (a) 固定阈值描单点
 - (b) 类别概率做阈值遍历画曲线
 - (c) 朴素贝叶斯不能输出概率
 - (d) 多分类无法画 ROC
- ODE 独依赖估计定义 ()
 - (a) 全部特征两两依赖
 - (b) 每个特征除类别至多依赖一个特征
 - (c) 忽略离散属性
 - (d) 全特征互相依赖
- TAN 树增强朴素贝叶斯正确 ()
 - (a) 全特征依赖同一超父
 - (b) 最大带权生成树构造依赖
 - (c) 复杂度低于朴素贝叶斯
 - (d) 无特征依赖

3 填空题

- 在线性回归的显著性检验中，_____ 检验用于检验单个自变量对因变量的影响是否显著，_____ 检验用于检验所有自变量整体对因变量的影响是否显著。
- 在进行回归模型选择时，常用的准则有赤池信息准则（AIC）和贝叶斯信息准则（BIC）。这两种准则不仅考虑模型拟合优度，还包含对模型复杂程度（自变量个数 p ）的惩罚。根据公式，AIC 准则的惩罚项系数是_____，BIC 准则的惩罚项系数是_____（填包含样本量 n 的数学公式）。当样本量 $n \geq 8$ 时，由于_____，BIC 比AIC 的惩罚力度要大。因此，往往BIC 选出来的变量个数要_____（填“多于”或“少于”）AIC 选出来的变量个数。
- 在模型 $\ln(y) = \beta_0 + \beta_1 \ln(x)$ 中，系数 β_1 表示 x 每变动1%， y 平均变动_____。
- 在线性回归模型中，方差膨胀因子VIF 用于检验_____ 问题，通常VIF 大于_____ 时表示存在严重共线性；在二手房案例中，经检验最大VIF 为5，说明该问题_____。若存在多重共线性，可以使用_____ 方法解决。
- 请写出经典线性回归模型 $Y = X\beta + \varepsilon$ 下，对于随机误差项 ε 的假设：_____。
- 在模型诊断中，若残差图（横轴为预测值，纵轴为残差）呈现出明显的“喇叭状”（即残差随预测值增大而波动增大），这通常意味着模型违反了随机误差项的_____ 假设；若要修正这一问题，可采用_____。



Logistic Function 和 Logit Function 的区别

答案:Logistic 是输入映射到概率,Logit 是概率映射到输入,二者是互为反函数的关系 (答出两者互为反函数的关系,输入与概率的自变量和因变量对应即可)

解析: 由于两者互为反函数所以相当于知道 x 求 y 和知道 y 求 x 。

Log-rank $p=0.12$, Wilcoxon $p=0.01$, 差异集中在申请周期早期

解析:Log-rank 权重全 1 对后期敏感, Wilcoxon 权重 n_i 对早期敏感。



生存无法观测确切失效时间叫删失; 风险建模Cox;Cox 与 AFT 系数符号相反

解析:Cox 建模风险, AFT 建模生存时长, 系数符号相反。

双因素无重复 SST=SSA+SSB+SSAB+SSE; 交互显著代表一个因素的作用依赖于另一个因素的水平;

Cox: $h(t, X) = h_0(t)e^{\beta X}$, $h_0(t)$ 是所有自变量 $X=0$ 时瞬时风险;Cox 半参数不用基准分布,

AFT 参数需指定分布; 泊松: 计数 数据, 连接对数函数, 过离散换负二项回归。

- 在 K-means 聚类算法中，算法的目标是最小化各样本点到所属聚类中心的_____。
- 在聚类建模过程中，如果不同变量的量纲或变化范围差异较大，为避免某些变量对聚类结果产生过大影响，通常需要先进行_____；同时，许多聚类方法对_____ 较为敏感，可能导致聚类方案被扭曲。

➤ 在因子分析中，通过_____操作可以使每个原始变量尽可能只在一个公共因子上有较高载荷，从而让因子的解释性更强；而主成分分析不能进行该操作，其根本原因是主成分是原始变量的_____线性组合，结果具有唯一性。

➤

题目：K-means 聚类算法试图最小化_____（英文缩写或全称），其定义式为 $\sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$ 。为了选择最优的聚类数 K ，常采用_____图，寻找曲线的_____作为合适的 K 值。

➤

题目 3：在因子分析正交模型 $Y - \mu = LF + \epsilon$ 中，每个原始变量 Y_j 的方差可以分解为两部分：一部分是由 m 个公共因子贡献的方差，称为_____；另一部分是无法由公共因子贡献的方差，称为唯一性。为了使载荷矩阵的结构更简单、更容易解释业务意义，通常会使用最大方差法等方法进行因子旋转。从几何角度看，在进行正交旋转后，各个变量的上述“由公共因子贡献的方差”部分的值_____（填“会”或“不会”）发生改变。

➤ CART 分类树最小化_____。ID3：_____；C4.5：_____；CART：_____；

➤

Bootstrap 极限不采样占比：36.8%；XGB 正则 $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$ ： T =叶子节点总数， w =叶子权重向量。

解析： $1/e \approx 36.8\%$ ； γ 惩罚叶子数量， λ 惩罚叶权重，共同约束树复杂度防过拟合。

Bagging 基学习器并行；Boosting 串行；拉普拉斯假设特征类别均匀分布，引入偏差。

解析：Bagging 各树独立训练并行；Boosting 依赖前一轮结果串行；拉普拉斯强制均匀先验，引入人为偏差。

零概率用拉普拉斯修正；Bagging 采用自助 (Bootstrap) 抽样；树全生成后自底向上剪枝：后剪枝；召回率：正例预测正确占比。

解析：概念固定考点，区分预剪枝与后剪枝定义。

➤ $\text{Ent}(D) = 0.971$ ， $D_1(6) : \text{Ent} = 0.650$ ， $D_2(4) : \text{Ent} = 0.811$ ， $\text{Gain} = \underline{\hspace{2cm}}$ 。



假设你正在为某市的“12345 政府热线”开发一个预测模型，任务是根据工单的结构化属性，例如：来电时间、诉求分类、紧急程度、区域代码等，对该工单的处理时长进行预测。团队目前在使用基于决策树的模型（如 XGBoost、LightGBM 等集成树）以及使用神经网络中产生分歧。请从以下三个维度对比两者，并给出你的首选推荐以及理由：

1. 计算资源与训练速度
2. 对异常值的鲁棒性
3. 向非技术领导汇报时的沟通成本（模型可解释性）

【答案与解析】：1. 维度对比分析：

1. 计算资源与训练速度：基于决策树模型：训练速度极快，对计算资源要求较低。在普通的 CPU 多核环境下即可实现极高的训练效率。神经网络：训练速度较慢，通常需要大量的 Epoch 进行迭代，整体的计算成本和时间成本远高于树模型。
 2. 对异常值的鲁棒性：基于决策树模型：鲁棒性极强。极端异常值只会影响排序末端，不会对树的结构产生剧烈破坏。神经网络：对异常值极其敏感。神经网络依赖梯度下降进行参数更新，未经处理的极端异常值会产生巨大的误差梯度，导致模型产生剧烈动荡。因此，训练前必须进行严格的缺失值填充和数据标准化。
 3. 可解释性：基于决策树模型：具有极高的业务可解释性。训练后可以输出全局的特征重要性。神经网络：被称为“黑盒模型”。其内部是复杂的非线性激活以及权重矩阵的组合，难以解释某个预测结论的具体逻辑，沟通成本高。
2. 推荐及理由：推荐：基于决策树的模型理由：决策树模型适合结构化表格数据，而神经网络适合非结构化或高维复杂数据。同时，该模型在训练成本、抗异常值干扰以及可解释性方面具有显著优势，符合该业务场景的需求。
- 解析：场景是结构化工单数据，树模型天然适配表格数据，神经网络更适配图像、文本非结构化数据。